UNIVERSIDADE FEDERAL DE SANTA CATARINA
CENTRO TECNOLÓGICO
DEPARTAMENTO DE AUTOMAÇÃO E SISTEMAS

Daniel Floriani da Silva

Relatório de Estágio

Extração, Transformação e Carregamento de dados: Um projeto prático utilizando a Arquitetura Medallion

Florianópolis

2026

Daniel Floriani da Silva

Extração, Transformação e Carregamento de dados: Um projeto prático utilizando a Arquitetura Medallion

Relatório submetido à Universidade Federal de Santa Catarina como requisito para a aprovação na disciplina **DAS 5501 - Estágio em Controle e Automação Industrial** do curso de Graduação em Engenharia de Controle e Automação.
Orientador: Leandro Buss Becker

Florianópolis

2026

Daniel Floriani da Silva

Extração, Transformação e Carregamento de dados: Um projeto prático utilizando a Arquitetura Medallion

Este relatório de estágio foi julgado no contexto da disciplina DAS5501: Estágio em Controle e Automação Industrial e **APROVADO** na sua forma final pelo Curso de Engenharia de Controle e Automação.

Florianópolis, 15 de abril de 2026

Leandro Buss Becker
Orientador
Universidade Federal de Santa Catarina

Vinicius Rios Fuck
Supervisor na Empresa
EMPRESA

Resumo

O presente relatório de estágio descreve o desenvolvimento de uma solução automatizada para a empresa Veeries, organização que atua no setor do agronegócio oferecendo produtos de análise de mercado e fluxo de *commodities*. O problema central abordado foi o severo gargalo operacional na ingestão de dados oriundos de relatórios em formato PDF de fontes duas fontes externas confidenciais. Tal extração era executada de forma estritamente manual pela equipe de analistas, consumindo cerca de três horas por lote e apresentando alta suscetibilidade a falhas humanas e estruturais. Para solucionar este desafio tecnológico e de negócio, foi projetado e implementado um *pipeline* de dados orientado a eventos, fundamentado na Arquitetura *Medallion* (composto pelas camadas progressivas *Bronze, Silver* e *Gold*) e construído na linguagem Python, com suporte das bibliotecas Pandas e Pandera. O fluxo automatizou a extração bruta do formato não estruturado e implementou rigorosos Contratos de Dados (*schemas*) para validações matemáticas e semânticas, além de adotar uma estratégia arquitetural de interrupção imediata em caso de anomalias estruturais (*fail-fast*). Como resultado direto da implantação, o tempo de processamento de um lote de relatórios foi reduzido de horas para um intervalo de 2 a 5 segundos. A esteira automatizada transferiu a responsabilidade técnica integralmente para a equipe de desenvolvedores, livrou os analistas de mercado de tarefas braçais de transcrição e conferiu alta governança, rastreabilidade e resiliência ao banco de dados da organização. O sistema provou-se capaz de interceptar e bloquear erros de publicação oriundos das próprias fontes emissoras antes que alcançassem as ferramentas analíticas e de tomada de decisão da diretoria.

Palavras-chave: Engenharia de Dados. Arquitetura *Medallion*. *Pipeline* de Dados. Qualidade de Dados. Automação.

Abstract

This internship report describes the development of an automated solution for Veeries, an organization operating in the agribusiness sector that offers market analysis and commodity flow products. The core problem addressed was the severe operational bottleneck in the data ingestion of PDF reports from two confidential external sources. This extraction was performed strictly manually by the analyst team, consuming about three hours per batch and presenting a high susceptibility to human and structural failures. To solve this technological and business challenge, an event-driven data pipeline was designed and implemented based on the Medallion Architecture (composed of progressive Bronze, Silver, and Gold layers) and built in Python, supported by Pandas and Pandera libraries. The workflow automated the raw extraction from the unstructured format and implemented strict Data Contracts (schemas) for mathematical and semantic validations, in addition to adopting an architectural strategy of immediate interruption in case of structural anomalies (fail-fast). As a direct result of the deployment, the processing time of a report batch was reduced from hours to an interval of 2 to 5 seconds. The automated pipeline transferred the technical responsibility entirely to the developers' team, freed market analysts from manual transcription tasks, and provided high governance, traceability, and resilience to the organization's database. The system proved capable of intercepting and blocking publication errors from the issuing sources themselves before they reached the analytical and decision-making tools of the board.

Key-words: Data Engineering. Medallion Architecture. Data Pipeline. Data Quality. Automation.

Lista de ilustrações

Figura 1 – Diagrama de Arquitetura do *Pipeline Medallion* 18
Figura 2 – Fluxo de Processamento de `main_source_X.py` ou `main_source_Y.py` 20
Figura 3 – Trecho de Código - Implementação de Contrato de Dados com Pandera 23
Figura 4 – Trecho de Código - Rotina Lógica de Validação e Reconciliação 25
Figura 5 – Trecho de Código - Orquestração e Propagação de Erros em Cascata . 26

Sumário

1 INTRODUÇÃO 7

2 A EMPRESA E O PROBLEMA 10

3 ASPECTOS CONCEITUAIS 12

4 A ARQUITETURA DA SOLUÇÃO 17

5 A IMPLEMENTAÇÃO DO *PIPELINE* 21

6 RESULTADOS E DISCUSSÕES 27

7 CONSIDERAÇÕES FINAIS E PERSPECTIVAS 29

REFERÊNCIAS 31

APÊNDICE A – GLOSSÁRIO DE TERMOS TÉCNICOS 32

1 Introdução

O presente relatório de estágio aborda o desafio da estruturação e da confiabilidade no consumo de dados corporativos. O problema central a ser resolvido consiste na fragilidade, morosidade e na falta de padronização durante a ingestão manual de dados provenientes de fontes externas críticas para o negócio, specificamente os relatórios em PDF (*Portable Document Format*) de duas fontes confidenciais, tratadas aqui como Fonte X e Fonte Y.

Este trabalho foi desenvolvido durante o Estágio Obrigatório realizado na empresa Veeries, em Florianópolis (SC), no período de outubro de 2025 a abril de 2026. O projeto insere-se no contexto do curso de Engenharia de Controle e Automação da Universidade Federal de Santa Catarina (UFSC), aplicando conhecimentos da grande área de informática industrial, especificamente no que tange a estruturas, processamento e automação de fluxos de dados, para a resolução de problemas práticos de mercado.

A confiabilidade dos dados é um fator crítico para a tomada de decisão nas organizações. A ausência de um tratamento automatizado e adequado pode gerar inconsistências silenciosas que impactam negativamente as análises gerenciais e estratégicas da equipe de mercado. A escolha deste tema justifica-se pela oportunidade de aplicar boas práticas de engenharia de *software* e de dados para mitigar esses riscos de intervenção humana, garantindo a integridade e a qualidade das informações disponibilizadas.

1.1 Objetivos

O objetivo geral deste estágio foi desenvolver e implementar um *pipeline* (uma esteira automatizada de fluxo de dados) para a extração, processamento e validação das informações provenientes das fontes X e Y.

Como objetivos específicos, destacam-se:

- Projetar o fluxo de dados fundamentado na Arquitetura *Medallion* (um modelo de organização em camadas progressivas de qualidade: *Bronze, Silver* e *Gold*).
- Desenvolver rotinas programáticas de extração bruta de dados (*parsers*) a partir de arquivos de formato complexo e não estruturado.
- Implementar rigorosas validações de qualidade e limpeza estrutural utilizando *schemas* (contratos técnicos que definem o formato esperado da informação).

A argumentação principal deste trabalho é que a adoção da Arquitetura *Medallion*, aliada à implementação de contratos de dados estritos na transição entre as camadas

de processamento, é capaz de garantir um fluxo de informação resiliente, rastreável e auditável, solucionando definitivamente o gargalo operacional da despadronização inicial.

1.2 Metodologia

A metodologia adotada possui um caráter eminentemente prático e aplicado, com foco no relato das técnicas e ferramentas utilizadas no desenvolvimento da automação, adequando-se ao rigor teórico esperado para um relatório de estágio técnico. Trata-se de um projeto de arquitetura de *software* em nível de produção.

Para a sua consecução, foram arquitetados e codificados *scripts* em linguagem Python atuando como orquestradores (`main_source_[X,Y].py`). Estes coordenam os módulos de processamento progressivos (`[l0,l1,l2,view]_process.py`) para transitar a informação entre as camadas do sistema, assegurados por regras de validação tipada e reconciliação matemática.

Como alternativa de solução frente aos modelos tradicionais de integração de dados executados em lote único (onde extração, transformação e carregamento ocorrem sem zonas de quarentena ou auditoria intermediária), optou-se pela Arquitetura *Medallion*. Essa abordagem permite o armazenamento dos arquivos em estados progressivos de refinamento em nuvem, facilitando a auditoria contínua e a manutenção paliativa pontual sem a necessidade de reprocessar todo o sistema em caso de falhas na fonte (GUJJALA, 2023).

1.3 Estrutura do Relatório

Para descrever o desenvolvimento e os resultados alcançados, o plano adotado para este relatório está organizado da seguinte maneira:

- O **Capítulo 2** descreve o contexto da empresa, detalhando a divisão das equipes, os conceitos primários sobre dados e os pormenores do problema motivador do estágio.
- O **Capítulo 3** apresenta, de forma concisa e prática, o embasamento bibliográfico da Arquitetura *Medallion* e das técnicas de validação de dados utilizadas na solução.
- O **Capítulo 4** descreve a arquitetura macro da solução, o ambiente de execução e a evolução estrutural (granularidade) dos arquivos ao longo do fluxo.
- O **Capítulo 5** detalha a implementação técnica da solução, expondo as ferramentas tecnológicas adotadas e o desenvolvimento das rotinas de orquestração, validação, transformação analítica e monitoramento aplicadas em cada camada da Arquitetura *Medallion*.

- O **Capítulo 6** expõe os resultados e promove uma análise crítica profunda sobre os ganhos reais de confiabilidade e desempenho alcançados na organização.
- Por fim, o **Capítulo 7** reúne a síntese interpretada dos resultados, avalia o cumprimento dos objetivos traçados e aponta perspectivas para trabalhos futuros.

2 A Empresa e o Problema

A Veeries é uma empresa de inteligência de mercado inserida no agronegócio, com sede no Parque Tecnológico Alpha, no bairro João Paulo, em Florianópolis. A organização oferece produtos relacionados à análise da produção, fluxo e operações de commodities, bem como fluxo e operações dos suprimentos e infra-estrutura relacionados a este mercado. A empresa conta com cerca de 20 funcionários e pode ser subdividida em duas equipes: uma de Analistas de Mercado e outra de Desenvolvedores, como assim são chamados na organização.

Próximo ao produto final, os analistas são responsáveis por analisar as informações coletadas, fazer projeções e montar relatórios. Estritamente ligados ao processamento da informação, o time de desenvolvedores é composto por engenheiros, cientistas da computação e estudantes de áreas correlatas. São responsáveis pela melhoria do processo, desde a obtenção dos dados até a apresentação ao cliente.

Como grande parte das fontes de informação externas da empresa disponibilizam seus relatórios em formato nativo de PDF, a ausência de uma estrutura tabular pré-definida (como a encontrada em bancos de dados relacionais ou planilhas) torna a extração e a integração automatizada desses arquivos um desafio tecnológico e operacional significativo.

2.1 O Problema de Extração e Validação

Historicamente na Veeries, a extração de dados oriundos de duas fontes externas essenciais para o mercado (tratadas de forma confidencial neste relatório como Fonte X e Fonte Y) representava um severo gargalo operacional. Os arquivos, recebidos com uma frequência mensal, exigiam uma atividade de extração estritamente manual por parte da equipe de analistas.

O fluxo de trabalho consistia na consulta visual dos arquivos em formato PDF e na transcrição manual dos valores e tabelas para planilhas do Excel. Por se tratar de um processo rudimentar e não estruturado, a atividade era extremamente morosa: consumia-se, em média, 3 horas de trabalho humano por lote de relatórios para a extração, checagem visual e organização dos dados.

Além do elevado custo de tempo, esse modelo manual era altamente suscetível a falhas humanas. Não havia uma validação sistêmica clara ou contratos de dados (regras estritas de formatação) que garantissem que a extração manual havia ocorrido sem erros de digitação ou deslocamento de linhas. Como consequência direta do esforço desproporcional exigido e da baixa confiabilidade do processo, essas fontes de informação acabavam sendo

pouco consideradas ou subutilizadas nas análises de mercado da empresa.

É exatamente para solucionar esse gargalo que o desenvolvimento de um *pipeline* de dados robusto se fez necessário, transferindo a responsabilidade da ingestão e operação técnica integralmente para a equipe de desenvolvedores. Com isso, os analistas foram liberados para o seu papel central de inteligência de mercado, consumindo apenas os dados validados no final do processo. A arquitetura dessa automação será detalhada nos capítulos a seguir.

3 Aspectos Conceituais

Para solucionar o problema da extração manual e garantir a confiabilidade dos dados ingeridos pela Veeries, fez-se necessário o uso de padrões arquiteturais consolidados na área de engenharia de dados. Este capítulo apresenta a fundamentação teórica sobre a classificação estrutural de dados, os conceitos primários de integração, a Arquitetura *Medallion* e a utilização de Contratos de Dados.

3.1 Estruturas de Dados e *Pipelines* ETL

O processo fundamental para a integração de bases de dados é conhecido como ETL (*Extract, Transform, Load* — Extração, Transformação e Carregamento). Em arquiteturas modernas, essas rotinas são implementadas através de *pipelines* de dados — conjuntos automatizados de processos que coletam informações de múltiplas fontes, realizam a limpeza e a validação, e as carregam em repositórios confiáveis para a tomada de decisão (GUJJALA, 2023; POLISETTY; PENDYALA; PRABHAKARAN, 2023). Em oposição aos processos manuais, a adoção desses fluxos contínuos mitiga drasticamente a ocorrência de falhas humanas (REIS; HOUSLEY, 2022).

A complexidade da etapa de extração em um *pipeline* ETL é diretamente proporcional ao nível de organização nativa da fonte. Na engenharia de dados, as informações são comumente classificadas em três grandes grupos: estruturadas, semiestruturadas e não estruturadas (GUJJALA, 2023).

Dados estruturados (como bancos de dados relacionais) exigem o menor esforço de processamento, pois já se encontram dispostos em linhas e colunas prontas para o consumo. Dados semiestruturados não se encaixam em tabelas estritas, mas possuem marcadores lógicos bem definidos (como arquivos JSON). Por fim, os dados não estruturados não possuem uma organização tabular ou relacional pré-definida para a extração computacional (como a grande maioria dos PDFs). Embora esses arquivos possuam uma formatação visual clara para a leitura humana, eles carecem de marcações lógicas que delimitem as variáveis, o que exige o maior esforço algorítmico no processamento primário (GUJJALA, 2023).

A qualidade dos dados (*Data Quality*) é o objetivo central dessas rotinas estruturadas, sendo avaliada com base em fatores como precisão, completude e consistência (POLISETTY; PENDYALA; PRABHAKARAN, 2023). Como o presente projeto lida majoritariamente com o desafio de transitar informações do formato não estruturado (tabelas desenhadas dentro de PDFs) para o formato tabular estruturado, a automação do fluxo através de um *pipeline* é o primeiro passo obrigatório para estabelecer a confiabilidade

do que será entregue aos analistas de mercado.

3.2 Arquitetura *Medallion* e Fragmentação de Ingestão

Para organizar o *pipeline* de maneira escalável, de fácil manutenção e rastreável, optou-se pela utilização da Arquitetura *Medallion*. Trata-se de um padrão de projeto de organização de dados que divide os arquivos e processamentos em camadas lógicas, com o objetivo de melhorar progressivamente a estrutura e a qualidade das informações a cada nova etapa (Databricks, 2023; GUJJALA, 2023).

Nesta arquitetura, a transição e o refinamento dos dados ocorrem na seguinte divisão:

- **Camada *Bronze* (L0):** Consiste na camada inicial de armazenamento após a extração dos dados originais. Neste projeto, os arquivos provenientes da camada anterior (arquivos PDF) são processados para um formato tabular e, para lidar com a imprevisibilidade dessas fontes, a camada *Bronze* foi estrategicamente fragmentada em duas subzonas de mesma estrutura: a L0 Original e a L0 Revisada.

  A **L0 Original** recebe o processamento inicial e mantém os arquivos totalmente intactos. Não há nenhuma intervenção nesta subcamada; ela atua como um registro imutável do sistema, garantindo a rastreabilidade e a possibilidade de auditoria exata do que foi extraído (GORELIK, 2019).

  A **L0 Revisada** Atua como uma zona de ajuste dos dados. Caso os dados extraídos não passem nas etapas de validação das camadas subsequentes (principalmente na L1) porque a fonte não seguiu o padrão esperado, o dado é reestruturado aqui. Desta maneira, o pipeline pode ser executado novamente sem a necessidade de reprocessar o dado na camada Bronze.

- **Camada *Silver* (L1):** Trata-se da camada intermediária. Nela, os dados tabulares provenientes da L0 Revisada são submetidos a rigorosos processos de limpeza, padronização, deduplicação e, principalmente, validação contra contratos predefinidos. É o estágio onde a informação deixa de ser um dado bruto e passa a ser um dado confiável e estruturado (GUJJALA, 2023).

- **Camada *Gold* (L2):** É a camada final de processamento do repositório. Os dados, já limpos e validados, são agregados e transformados conforme as regras abrangentes da organização, ficando otimizados e prontos para o consumo analítico (Databricks, 2023).

3.3 Camada de Apresentação (*Views*) e Versatilidade

Embora a camada *Gold* finalize o tratamento da informação, a entrega direta de tabelas físicas aos usuários analistas pode gerar engessamento. Para solucionar isso, as modernas arquiteturas de engenharia de dados adotam uma Camada de Apresentação (frequentemente materializada através de *Views* lógicas) operando sobre a camada *Gold* (REIS; HOUSLEY, 2022).

Uma diretriz de projeto fundamental adotada neste trabalho foi a de propagar o máximo de campos e informações viáveis extraídas da fonte primária até a camada anterior à apresentação (L2). A premissa central de preservar a abrangência e a granularidade atômica dos dados garante uma extrema versatilidade ao *pipeline* (KIMBALL; ROSS, 2013).

Se o cliente final (analista de mercado) alterar seus requisitos de negócio e solicitar a visualização de uma coluna extraída do PDF que não havia sido prevista nos relatórios iniciais, essa arquitetura evita retrabalho. Como o dado já foi extraído da fonte, validado na L1 e preservado até a camada L2, não há necessidade de reconstruir os *scripts* de ingestão: basta editar os limites da *View* para passar a expor a nova métrica. Esse desacoplamento entre armazenamento estruturado e apresentação final eleva a resiliência operacional da solução.

3.4 Contratos de Dados e *Schemas*

Um dos principais desafios na ingestão de arquivos externos é a mudança inesperada na estrutura original dos dados, como o reposicionamento de valores em um PDF. Para evitar que essas alterações corrompam silenciosamente os relatórios finais da empresa, utilizam-se os Contratos de Dados (*Data Contracts*), que são acordos técnicos estritos definindo o formato, a estrutura e a tipagem esperada das informações na transição entre as camadas do *pipeline* (KLEPPMANN, 2017; ARMBRUST et al., 2020).

A principal ferramenta lógica para impor o cumprimento desses contratos é o *Schema* (Esquema). O *schema* especifica claramente os nomes das colunas, os tipos de dados exigidos e as restrições de obrigatoriedade (LIAO; ZHANG; LIN, 2020).

Ao se aplicar a imposição de esquemas (*schema enforcement*) na transição entre a L0 Revisada e a camada *Silver*, o sistema atua como uma barreira de segurança: registros que não cumprem os requisitos estruturais preestabelecidos são bloqueados ou sinalizados para correção. Essa prática é essencial para lidar com a evolução estrutural dos dados, protegendo o sistema contra quebras e garantindo que apenas informações íntegras fluam para as *Views* de apresentação (ARMBRUST et al., 2020).

3.5 Estratégias de Validação e Reconciliação de Dados

Para assegurar a integridade da informação propagada pelo *pipeline*, não basta apenas impor a tipagem de dados através de *schemas*; é fundamental garantir a coerência matemática e lógica dos valores extraídos da Fonte X e da Fonte Y. Para isso, são empregadas técnicas de reconciliação de dados, divididas conceitualmente em validações horizontais, verticais e verificações de duplicidade (POLISETTY; PENDYALA; PRABHAKARAN, 2023).

Na transição dos dados brutos (L0) para a camada intermediária estruturada (L1), aplicam-se duas validações matemáticas principais:

- **Validação Vertical:** Atua no nível das colunas. O seu objetivo é garantir que a soma de todos os valores de uma determinada métrica extraída corresponda exatamente ao valor totalizador geral divulgado pela própria fonte em uma linha de totalização.
- **Validação Horizontal:** Opera no nível da instância (linha). Esta verificação assegura que, para um dado registro específico, a soma das variáveis parciais que o compõem resulte no valor idêntico à coluna de total correspondente àquela mesma linha.

A necessidade estrita dessas abordagens de reconciliação matemática surge da criticidade inerente aos processos de extração (*parsing*) de arquivos não estruturados. Durante a varredura automatizada de relatórios em PDF, formatações visuais imprevistas podem levar ao truncamento de dados ou ao tratamento inadequado de caracteres delimitadores. Se a fonte externa alterar subitamente o padrão de separadores de milhar ou decimal (como a inversão de pontos por vírgulas), as validações de esquema que atuam apenas na checagem da tipagem do dado interpretariam o valor como válido, permitindo a passagem de uma inconsistência numérica silenciosa.

Nesse cenário, a validação horizontal e vertical atua como uma malha fina estatística que detecta essas anomalias de formatação e arredondamento, garantindo que o valor extraído da matriz faça sentido em relação aos seus totais antes de ser propagado para as ferramentas de tomada de decisão (POLISETTY; PENDYALA; PRABHAKARAN, 2023). Por lidarem com possíveis variações de arredondamento da própria fonte, essas validações são projetadas com margens de tolerância ajustáveis. Isso garante que o *pipeline* seja resiliente a flutuações decimais irrelevantes, mantendo a continuidade do processamento sem abrir mão da confiabilidade estrutural.

Por fim, a **validação de unicidade** (*uniqueness validation*) é uma etapa crucial para garantir que não existam registros estritamente duplicados trafegando pelo *pipeline*. Diferente de lógicas de filtragem temporal ou de versão de documentos, a validação de unicidade assegura que uma mesma instância — definida por um conjunto específico de chaves compostas (*composite keys*) — apareça apenas uma vez no modelo.

Essa verificação atua como uma malha fina de segurança em etapas onde ocorrem operações estruturais complexas na modelagem, como o despivoteamento de tabelas para o formato longo (*Melt*) ou cruzamentos entre bases (*Joins*). Tais operações carregam o risco inerente de multiplicar linhas indevidamente em caso de falha algorítmica (fenômeno conhecido como *fan-out*). Validar a unicidade de forma programática protege a integridade atômica do modelo, garantindo que as métricas não sejam contabilizadas em duplicidade nas análises finais (REIS; HOUSLEY, 2022).

4 A Arquitetura da Solução

Para sanar o gargalo operacional imposto pela extração manual de dados não estruturados, foi concebida uma arquitetura baseada em eventos lógicos e armazenamento em nuvem. Este capítulo descreve conceitualmente o novo fluxo de informações da Veeries, detalhando o ambiente de execução, o ciclo de vida dos arquivos e a transição da granularidade (nível de detalhamento) dos dados através das camadas do *pipeline*.

4.1 Ambiente de Execução e Orquestração

A infraestrutura de armazenamento do projeto foi estabelecida sobre o ecossistema de nuvem sincronizada da organização (utilizando as plataformas *OneDrive/SharePoint*). Essa escolha garante alta disponibilidade e espelhamento nativo dos arquivos do *pipeline* com as estações de trabalho da equipe.

Como as fontes externas não possuem uma data de publicação exata ou previsível para a emissão dos seus relatórios mensais em PDF, a adoção de um agendador de tarefas tradicional (baseado em tempo cronometrado) resultaria em execuções ociosas ou falhas por ausência de arquivos. Portanto, o acionamento do *pipeline* baseia-se em uma arquitetura orientada a eventos, com orquestração sob demanda.

O fluxo se inicia quando o desenvolvedor responsável pelo monitoramento recebe o documento da fonte (via e-mail ou portais do mercado). O arquivo é então salvo de maneira padronizada no diretório de entrada inicial do *pipeline* (denominado `01_RAW`). Após o armazenamento, o usuário aciona a execução do processamento através de um *bot* (robô virtual de automação) no aplicativo de mensagens *Telegram*, o qual atua como o gatilho externo. Este *bot* envia um comando (via *webhook*, um mecanismo de comunicação em tempo real, ou requisição de API - interface de comunicação entre sistemas) que inicia a rotina de execução do repositório no *GitHub* (plataforma em nuvem de hospedagem e versionamento de código-fonte), transferindo o processamento pesado para o ambiente em nuvem da aplicação.

4.2 Fluxo e Evolução Estrutural dos Arquivos

A Figura 1 apresenta o diagrama da Arquitetura *Medallion* implementada, ilustrando a transição dos dados desde a sua captura bruta até a disponibilização para os analistas de mercado. Uma diretriz central desta arquitetura foi o isolamento contínuo das fontes de dados durante as etapas primárias de limpeza e validação, a fim de evitar que

anomalias em um relatório comprometessem a ingestão do outro.

Figura 1 – Diagrama de Arquitetura do *Pipeline Medallion*

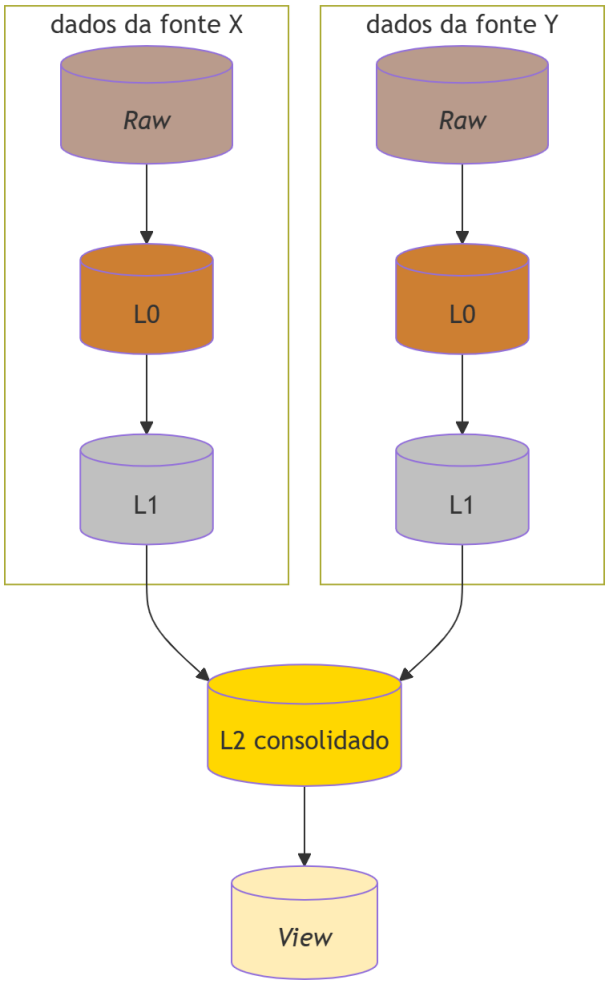

Fonte: Elaborado pelo autor.

Para operacionalizar esse fluxo lógico, a Figura 2 detalha visualmente as etapas de processamento executadas pelos algoritmos orquestradores da esteira.

A transição e consolidação da informação ocorrem de maneira gradativa através das camadas detalhadas a seguir:

- **Camada *Raw* (Crua):** Os arquivos que ingressam nesta camada preservam seu formato nativo (PDF). A granularidade é estritamente unitária: cada arquivo corresponde a um documento em PDF de uma única fonte de informação, retratando uma única data de emissão e um mês de referência específico. Os arquivos são mantidos em diretórios separados por fonte.
- **Camada *Bronze* (L0 Original e Revisada):** Após o acionamento do *parser* (algoritmo de extração de texto), o dado é convertido do formato PDF para arquivos

tabulares no formato .CSV (*Comma-Separated Values*), preservando a granularidade original. Assim, na camada L0, cada CSV gerado continua representando os dados de uma única fonte para uma referência temporal específica. A fragmentação da L0 permite a tolerância a falhas na extração do texto antes de avançar para as validações estruturais.

- **Camada *Silver* (L1):** A transição para a camada L1 engloba a imposição de esquemas e a validação matemática. A granularidade do arquivo sofre sua primeira alteração arquitetural: o arquivo gerado na camada L1 passa a representar a união consolidada de todos os arquivos históricos extraídos da L0 Revisada. Contudo, essa consolidação ainda ocorre de maneira particionada por fonte de informação. Isso garante que qualquer falha de validação ou processamento em uma das origens possa ser identificada e isolada sem interferir na disponibilidade dos dados da outra fonte.

- **Camada *Gold* (L2):** É na penúltima camada de processamento que ocorre a consolidação global do *pipeline*. Os dados validados das diferentes origens (Fonte X e Fonte Y) convergem para formar um único documento mestre de *data warehouse* (armazém central de dados) (KIMBALL; ROSS, 2013). A granularidade torna-se abrangente e multiorigem.

- **Camada de Apresentação (*View*):** Atuando como a interface final entre a engenharia de dados e a equipe de inteligência de mercado, esta camada lógica consome os dados consolidados da L2. Sua principal função na arquitetura é adequar a granularidade técnica para uma visão puramente de negócios: metadados exclusivos de auditoria do sistema são filtrados e instâncias redundantes (geradas por republicações de períodos anteriores) são ocultadas. O arquivo resultante finaliza o fluxo representando uma visão definitiva e cronologicamente atualizada, otimizada para o consumo direto pelas ferramentas de *Business Intelligence*.

Figura 2 – Fluxo de Processamento de `main_source_X.py` ou `main_source_Y.py`

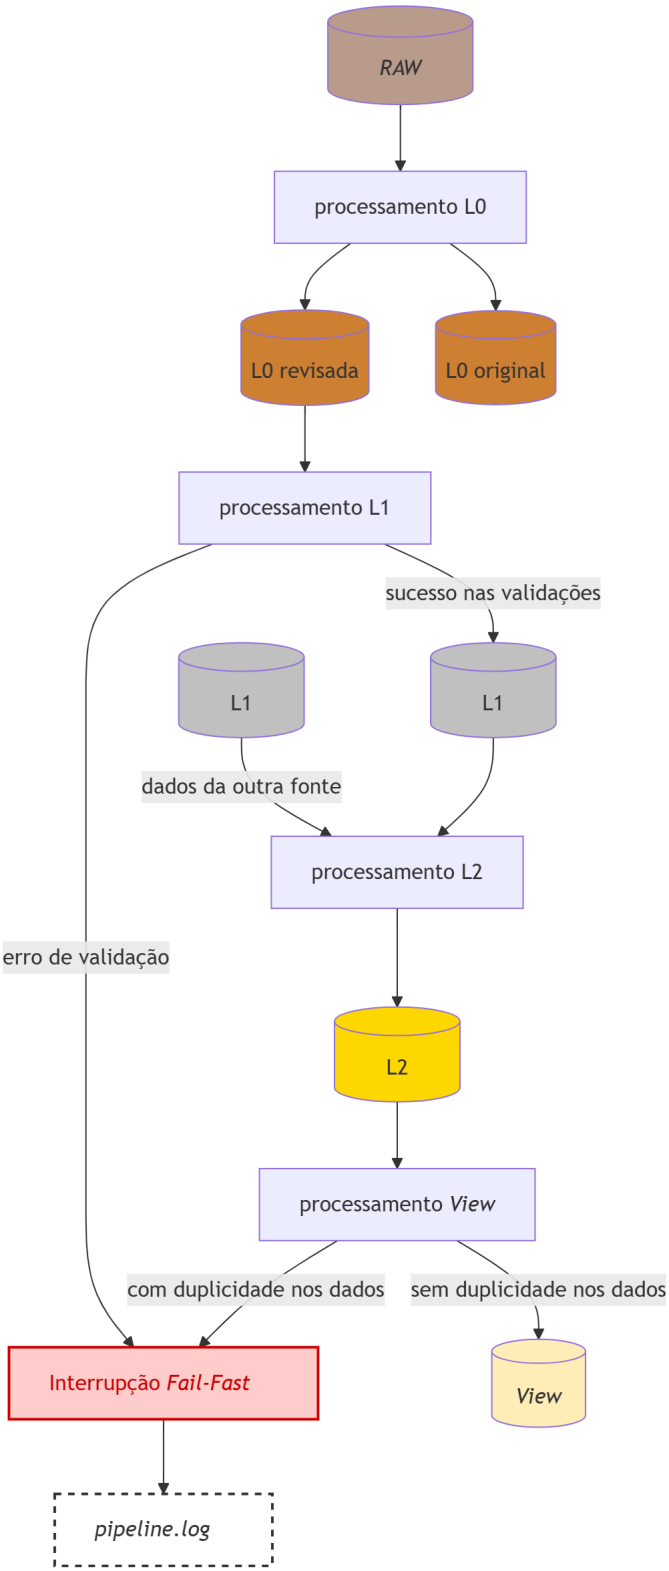

Fonte: Elaborado pelo autor.

5 A Implementação do *Pipeline*

Este capítulo detalha a implementação técnica da solução arquitetada, traduzindo os conceitos lógicos e os fluxos de informação apresentados anteriormente em rotinas de código. O foco desta seção é expor o ambiente de desenvolvimento, as diretrizes tecnológicas e a estruturação algorítmica utilizada para transitar, validar e consolidar os dados através da Arquitetura *Medallion*.

5.1 Ambiente de Desenvolvimento e Tecnologias

Todo o desenvolvimento do *pipeline* foi realizado utilizando a linguagem de programação Python. A definição do escopo tecnológico obedeceu a uma diretriz direta da equipe de desenvolvedores da Veeries, que estabeleceu o uso de bibliotecas específicas como requisito para garantir a integração e a padronização com o ecossistema de dados já existente na organização.

Para estruturar as transformações, o projeto foi construído sobre dois pilares de código aberto:

- **Pandas:** Biblioteca primária de manipulação e análise de dados em Python. Foi utilizada em todas as camadas do projeto para operações de união, cálculos de subtotais e limpeza de *strings*.
- **Pandera:** Biblioteca voltada para a validação estatística e estrutural de *DataFrames* (estruturas tabulares de dados). Atendendo à exigência da empresa por qualidade e governança, o Pandera foi a ferramenta empregada para materializar os "Contratos de Dados", garantindo a imposição de esquemas (*schema enforcement*) durante a execução do código.

O código-fonte foi versionado utilizando a plataforma *GitHub* e estruturado sob o paradigma de Programação Orientada a Objetos (POO), garantindo a modularidade e o reaproveitamento de rotinas entre diferentes origens de dados.

5.2 Orquestração e Ingestão (Camada *Bronze*)

O fluxo de execução do projeto é coordenado por *scripts* orquestradores (`main_source.py`), responsáveis por acionar os módulos sequencialmente e interromper o processo imediatamente caso ocorra uma falha crítica em qualquer camada.

A primeira etapa do *pipeline* é operada pelo módulo `l0_process.py`. Este componente atua como o motor de ingestão da Camada *Bronze* (L0). O seu papel principal é varrer os diretórios de entrada (`01_RAW`), identificar novos relatórios em formato nativo e acionar os algoritmos de extração de texto (*parsers*).

Optou-se por abstrair a complexidade visual dos relatórios originais logo no momento da ingestão. O *parser* localiza os dados tabulares e os metadados primários (como a data de referência do relatório) e o módulo L0 salva essas informações no formato .CSV, mantendo a integridade exata do que foi lido (L0 Original). O armazenamento nesta camada utiliza um particionamento lógico em arquivos compactados organizados por ano e mês, otimizando o espaço em nuvem e facilitando a auditoria temporal.

5.3 Validação e Padronização (Camada *Silver*)

A transição para a Camada *Silver* (L1) é o ponto crítico para a governança do *pipeline*, sendo executada pelo módulo `l1_process.py`. É nesta etapa que os dados brutos deixam de ser tratados apenas como "texto"e passam a ser validados como regras de negócio.

A implementação dessa validação baseia-se fortemente no arquivo `schemas.py`, onde classes de validação definem os contratos estruturais. A Figura 3 apresenta um trecho do código desenvolvido demonstrando a imposição de tipagem da camada L1.

Conforme ilustrado, o sistema força que todas as instâncias possuam campos tipados corretamente (como datas de referência obrigatórias e colunas de identificação de origem). Caso a fonte externa altere a estrutura do seu relatório, o processo de validação acusará uma violação de contrato e interromperá a execução, bloqueando a propagação do erro.

Além da tipagem, o módulo `l1_process.py` realiza o mapeamento semântico. Através da leitura de dicionários de conversão, os nomes de categorias e variáveis que chegam despadronizados são normalizados para as nomenclaturas internas da empresa, centralizando o controle. A Figura 4 demonstra a estruturação de uma das lógicas de validação aplicadas no *pipeline*, a validação horizontal.

5.4 Transformação Analítica e Apresentação (Camadas *Gold* e *View*)

O refino final dos dados é dividido entre os módulos `l2_process.py` (Camada *Gold*) e `view_process.py` (Camada de Apresentação).

Na camada L2, a rotina executa a principal alteração estrutural do dado: a operação de *Melt* (despivoteamento). Essa técnica transforma variáveis dispostas horizontalmente

Figura 3 – Trecho de Código - Implementação de Contrato de Dados com Pandera

```python
class L1Schema(pa.SchemaModel):
    dt_timestamp: Series[DateTime] = pa.Field(coerce=True, nullable=False)
    dt_report: Series[DateTime] = pa.Field(coerce=True, nullable=False)
    dt_reference: Series[DateTime] = pa.Field(coerce=True, nullable=False)
    dt_report_assistant: Series[DateTime] = pa.Field(coerce=True, nullable=False)
    dt_periodo: Series[DateTime] = pa.Field(coerce=True, nullable=False)
    dt_circular: Series[DateTime] = pa.Field(coerce=True, nullable=True)
    dt_path: Series[DateTime] = pa.Field(coerce=True, nullable=False)
    class_report: Series[String] = pa.Field(nullable=False)
    nm_path: Series[String] = pa.Field(nullable=False)
    source: Series[String] = pa.Field(
        nullable=False, isin=["Fonte X", "Fonte Y"]
    )

    # Business metadata
    nm_product: Series[String] = pa.Field(nullable=False)
    nm_group: Series[String] = pa.Field(nullable=False)
    sg_product: Series[String] = pa.Field(nullable=True)
    nm_product_secex: Series[String] = pa.Field(nullable=True)
    id_sh4: Series[String] = pa.Field(nullable=True)

    # Value columns - Nullable Integers (pd.Int64Dtype) to handle missing data
    total_port: Series[float] = pa.Field(nullable=True, coerce=True)
    year_over_year_change: Optional[Series[Float]] = pa.Field(coerce=True, nullable=True)
```

Fonte: Elaborado pelo autor.

(por exemplo, múltiplas colunas representando diferentes segmentações regionais ou categorias) em linhas. Esse formato longo (*long format*) é o padrão exigido por ferramentas modernas de visualização. É também nesta camada que são processadas as agregações lógicas (subtotais sintéticos) e aplicadas as validações estritas de unicidade para prevenir a multiplicação indevida de instâncias geradas pela transformação.

Por fim, o módulo *View* abstrai toda a complexidade da engenharia para o usuário final. Ele atua removendo os metadados de auditoria técnica e executa um filtro de versão cronológica. Caso as fontes emitam relatórios redundantes ou retificados no mesmo período, o código utiliza a data de extração para deduplicar a base, garantindo que a versão entregue aos analistas reflita estritamente o cenário consolidado mais atual e fidedigno do mercado.

5.5 Monitoramento e Rastreabilidade

Conforme ilustrado anteriormente pelas ramificações de interrupção na Figura 2, para garantir a confiabilidade da operação contínua do *pipeline* em ambiente de produção, o sistema não permite o avanço de dados corrompidos. Para auditar esses bloqueios, foi implementada uma arquitetura de monitoramento baseada em *logs* (registros detalhados

de execução).

Através da parametrização no módulo de configuração (`config.py`), o sistema inicializa um *logger* global padronizado, emitindo alertas simultâneos para o terminal de controle e para um arquivo físico de auditoria armazenado em nuvem junto aos dados brutos.

Durante a orquestração executada pelos *scripts* principais (`main_source.py`), as rotinas de processamento adotam a estratégia de propagação de erros em cascata (*cascading error propagation*). A Figura 5 ilustra como o encadeamento sequencial das camadas foi implementado dentro de um bloco de controle de exceções.

Isso significa que a execução das camadas é estritamente interdependente. Se o módulo da camada *Silver* identificar uma quebra no contrato de dados (uma coluna nova não mapeada enviada pela fonte, por exemplo), o erro estrutural é capturado, registrado no *log* detalhado, e o *pipeline* é interrompido imediatamente.

A adoção dessa abordagem *fail-fast* (falhar rapidamente) é a etapa final de segurança arquitetural do projeto. Ela impede que um dado corrompido, não mapeado ou parcialmente validado avance e contamine as camadas *Gold* e de Apresentação. Dessa forma, assegura-se que a equipe de analistas de mercado consuma única e exclusivamente informações validadas, auditáveis e fidedignas, cumprindo o objetivo primário de qualidade de dados proposto no estágio.

Figura 4 – Trecho de Código - Rotina Lógica de Validação e Reconciliação

```python
def validate_horizontal_consistency(
    df: pd.DataFrame,
    cols_to_sum: List[str],
    col_target: str,
    col_filter: str,
    instances_to_exclude: List[str],
    tolerance: float,
    logger: logging.Logger
) -> Optional[pd.DataFrame]:
    """
    Realiza o cruzamento da soma de colunas específicas contra uma coluna de total/alvo.
    Args:
        df: DataFrame de entrada.
        cols_to_sum: Colunas que devem ser somadas para atingir o valor alvo.
        col_target: O total esperado.
        col_filter: Coluna usada para excluir linhas específicas (ex: totais já existentes).
        instances_to_exclude: Valores a serem ignorados na validação.
        tolerance: Erro absoluto permitido.
        logger: Instância do logger.
    Returns:
        None se for bem-sucedido.
    Raises:
        ValueError: Se as discrepâncias excederem a tolerância definida.
    """
    logger.debug(f"Verificando consistência horizontal para: {col_target}")

    if col_filter in df.columns:
        exclude_norm = [str(i).lower().strip() for i in instances_to_exclude]
        mask_valid = ~df[col_filter].astype(str).str.lower().str.strip().isin(exclude_norm)
        df_to_validate = df[mask_valid].copy()
    else:
        df_to_validate = df.copy()

    available_cols = [c for c in cols_to_sum if c in df_to_validate.columns]

    if not available_cols or col_target not in df_to_validate.columns:
        logger.warning(f"Validação ignorada: Coluna '{col_target}' ou colunas de origem ausentes.")
        return None

    # Conversão para numérico e tratamento de NaNs como zero
    temp_sum = df_to_validate[available_cols].apply(pd.to_numeric, errors='coerce').fillna(0)
    calc_sum = temp_sum.sum(axis=1)
    target_values = pd.to_numeric(df_to_validate[col_target], errors='coerce').fillna(0)

    diff = np.abs(calc_sum - target_values)
    inconsistent = diff > tolerance

    if inconsistent.any():
        num_errors = inconsistent.sum()
        df_errors = df_to_validate[inconsistent].copy()
        df_errors['calculated_sum'] = calc_sum[inconsistent]
        df_errors['target_value'] = target_values[inconsistent]

        msg = (f"Discrepância horizontal em '{col_target}'. "
               f"{num_errors} linhas falharam com tolerância de {tolerance}.")
        logger.error(msg)
        raise ValueError(msg)

    logger.debug(f"Checagem de consistência horizontal para '{col_target}': OK.")
    return None
```

Fonte: Elaborado pelo autor.

Figura 5 – Trecho de Código - Orquestração e Propagação de Erros em Cascata

```python
def main():
    """
    Ponto de entrada principal para a orquestração do ETL.
    Implementa a propagação de erros em cascata: a falha em qualquer camada interrompe toda a sequência.
    """
    logger = None
    try:
        # 1. Inicialização do Log de Auditoria Persistente
        logger_dir = SRC_X_DIR_CONFIG['LOG']['OUTPUT_DIR']
        logger = setup_logger(LOGGING, logger_dir)
        logger.info("--- [ INÍCIO DA EXECUÇÃO DO PIPELINE ETL ] ---")

        # 2. Execução L0: Ingestão de artefatos brutos em armazenamento particionado por ZIP
        logger.info(">>> Camada L0: Extração (Scraping) e Consolidação de Dados Brutos...")
        L0Processor(dir_config=SRC_X_DIR_CONFIG, parser_parameters=SRC_X_PARSER, logger=logger).run()

        # 3. Execução L1: Padronização, mapeamento e auditorias de integridade
        logger.info(">>> Camada L1: Padronização e Validação de Negócio...")
        L1Processor(dir_config=SRC_X_DIR_CONFIG, logger=logger).run()

        # 4. Execução L2: Transformação para formato longo e enriquecimento de subtotais
        logger.info(">>> Camada L2: Transformação Analítica (Gold)...")
        L2Processor(logger=logger).run()

        # 5. Execução View: Desduplicação final e entrega para apresentação
        logger.info(">>> Camada VIEW: Geração da Camada de Apresentação Final...")
        ViewProcessor(logger=logger).run()

        logger.info("--- [ EXECUÇÃO DO PIPELINE ETL CONCLUÍDA COM SUCESSO ] ---\n\n")

    except Exception as e:
        fatal_msg = f"PIPELINE ABORTADO: Erro fatal no orquestrador: {e}"
        if logger:
            logger.critical(fatal_msg)
            logger.critical(traceback.format_exc())
        else:
            print(fatal_msg)
            traceback.print_exc()
        raise RuntimeError(fatal_msg) from e

if __name__ == "__main__":
    main()
```

Fonte: Elaborado pelo autor.

6 Resultados e Discussões

Este capítulo apresenta a análise crítica dos resultados obtidos com a implantação do *pipeline* em ambiente de produção. O objetivo é avaliar a eficácia da solução proposta frente aos problemas de despadronização e morosidade detalhados no Capítulo 2, dimensionando os impactos quantitativos de desempenho e os ganhos qualitativos de governança de dados para a Veeries.

6.1 Impacto Operacional e Redução de Tempo de Processamento

O benefício imediato e mais expressivo da automatização foi o ganho de eficiência temporal. No paradigma anterior, o responsável pela obtenção dos dados dedicava cerca de 3 horas de trabalho humano aplicados à leitura, transcrição e a algum tipo de validação não estruturada em um lote de relatórios. Com a nova arquitetura, o tempo de extração, validação, cruzamento e consolidação dos dados despencou para um intervalo de execução entre 2 a 5 segundos.

Embora o monitoramento inicial da disponibilidade do dado permaneça uma etapa humana (uma vez que a fonte emissora não possui uma data previsível para a publicação dos relatórios), a natureza do trabalho do responsável pelos dados foi fundamentalmente transformada. A equipe deixou de atuar como "transcritora de dados"e assumiu o papel de curadoria e auditoria da informação. O esforço humano agora é alocado exclusivamente para interpretar o resultado do *pipeline* e analisar os dados já consolidados.

6.2 Governança, Resiliência e Tratamento de Exceções

Sob a perspectiva qualitativa, a adoção da Arquitetura *Medallion* e da estratégia *fail-fast* (falhar rapidamente) provou-se altamente eficaz na proteção do ambiente analítico da empresa. Durante os ciclos de operação real, o sistema de monitoramento conseguiu identificar e barrar a propagação de anomalias que, no método manual, passariam despercebidas.

Com o novo fluxo, quando o *pipeline* reporta uma interrupção de sucesso, o trabalho do desenvolvedor responsável restringe-se a investigar a causa apontada pelos *logs* e atuar em três frentes principais de exceção:

- **Produtos não mapeados:** Como os relatórios externos frequentemente introduzem categorias de produtos voláteis ou nomenclaturas inéditas, a validação de dicionário da camada *Silver* (L1) barra o processamento instantaneamente. O desenvolvedor

então apenas adiciona a nova instância ao dicionário central de mapeamento e reexecuta o código.

- **Inconsistências de estrutura nativa:** Quando a fonte altera ligeiramente a forma que publica os dados, o desenvolvedor realiza ajustes pontuais na camada L0 Revisada. Isso valida a premissa arquitetural discutida no Capítulo 3: é possível corrigir o formato de leitura sem perder a rastreabilidade original do documento preservado na L0 Original.
- **Auditoria de séries históricas e erros da fonte:** O impacto mais notável de qualidade de dados ocorreu durante a consolidação histórica das bases. As validações matemáticas identificaram o aparecimento de uma categoria de produto que não possuía sentido lógico na série temporal. A restrição estrutural revelou que a falha não era do algoritmo de extração, mas sim um erro de publicação da própria fonte externa emissora do relatório.

O bloqueio automático desse erro de publicação externa comprova o sucesso primário deste projeto. A implementação não apenas resolveu o problema de lentidão, mas instituiu uma malha fina de confiabilidade sistêmica. A Veeries agora possui a garantia de que os relatórios que abastecem suas ferramentas de tomada de decisão (BI) são estritamente fidedignos e auditáveis, eliminando o risco do consumo de dados corrompidos.

7 Considerações Finais e Perspectivas

Este capítulo apresenta a síntese interpretada dos resultados alcançados ao longo do estágio, avaliando o cumprimento dos objetivos propostos. Discutem-se também as limitações inerentes à solução desenvolvida e são traçadas perspectivas para trabalhos futuros.

7.1 Síntese e Avaliação dos Resultados

O desenvolvimento deste *pipeline* de extração e validação atingiu plenamente o objetivo de solucionar o gargalo operacional da Veeries. A substituição de um processo manual rudimentar, que consumia cerca de 3 horas de trabalho humano por lote de relatórios, por uma execução automatizada de até 5 segundos representa um ganho de eficiência evidente.

Do ponto de vista da governança, a adoção da Arquitetura *Medallion* e a aplicação rigorosa de Contratos de Dados mostraram-se escolhas arquiteturais acertivas. O método implementado foi significativamente superior à abordagem anterior, não apenas pela velocidade de ingestão, mas pela capacidade de trazer robustez ao repositório de informações. O sistema transferiu a responsabilidade da equipe de uma atuação repetitiva e transcritora para um papel analítico e de curadoria de negócio. O bloqueio automático e bem-sucedido de anomalias e erros gerados pela própria fonte emissora atesta que o código desenvolvido entregou o nível máximo de confiabilidade exigido para a tomada de decisão da empresa.

7.2 Limitações do Projeto

Apesar do sucesso operacional, a solução atual opera sob alguns pressupostos lógicos e possui limitações que devem ser pontuadas:

- **Dependência de Gatilho Humano:** Devido à imprevisibilidade na data e horário de publicação dos relatórios pelas fontes externas, o *pipeline* ainda depende que o desenvolvedor identifique visualmente a disponibilidade do arquivo (via portal ou e-mail) e acione o processamento através do *bot* no aplicativo *Telegram*.
- **Suscetibilidade a Mudanças Estruturais Severas:** O algoritmo de extração de texto (*parser*) foi desenhado para tolerar pequenas flutuações de margens e espaçamentos da fonte nativa. Contudo, se a entidade externa alterar drasticamente a disposição visual das tabelas no PDF, o sistema falhará intencionalmente (*fail-fast*)

para proteger a integridade dos dados, exigindo a intervenção nos métodos de captura dos dados nos arquivos brutos.

7.3 Perspectivas e Trabalhos Futuros

Tendo em vista que a arquitetura base do *pipeline* já garante a estabilidade da ingestão e a integridade estrutural dos dados, o projeto atinge uma maturidade operacional que possibilita a evolução para camadas mais avançadas de governança e inteligência analítica (GUJJALA, 2023). Focando na minimização dos riscos inerentes à intervenção manual e no incremento da qualidade da informação, destacam-se como sugestões lógicas para a continuidade deste trabalho:

- **Sistematização do Monitoramento e Curadoria:** Embora a transição e a validação do dado sejam automatizadas, a etapa de monitoramento da execução e a curadoria de exceções (como a inclusão de novos produtos no dicionário) dependem da ação do desenvolvedor. Sistematizar o ambiente de curadoria da informação é um passo futuro importante para garantir que a etapa humana, naturalmente suscetível a falhas ou atrasos, não comprometa a esteira de entrega final dos dados.

- **Implementação de Validação Numérica e Estatística:** O *pipeline* atual garante a integridade estrutural e a reconciliação matemática. Como evolução de maturidade do projeto, sugere-se a adição de uma malha de validação comportamental baseada em análise de série histórica. O sistema passaria a avaliar a curva esperada de uma determinada variável e, caso os dados numéricos extraídos fujam expressivamente do desvio padrão (caracterizando um *outlier*), o processamento acenderia um alerta prévio ao desenvolvedor para averiguação, adicionando uma rigorosa camada de validação semântica ao fluxo.

Referências

ARMBRUST, M. et al. Delta lake: High-performance acid table storage over cloud object stores. *Proc. VLDB Endowment*, v. 13, n. 12, p. 3411–3424, 2020. Citado 2 vezes nas páginas 14 e 33.

Databricks. *What is a Medallion Architecture?* 2023. <https://www.databricks.com/glossary/medallion-architecture>. Acesso em: 19 mar. 2026. Citado na página 13.

GORELIK, A. *The Enterprise Big Data Lake: Delivering the Promise of Big Data and Data Science*. [S.l.]: O'Reilly Media, 2019. Citado na página 13.

GUJJALA, P. K. R. Optimizing etl pipelines with delta lake and medallion architecture: A scalable approach for large-scale data. *International Journal for Multidisciplinary Research (IJFMR)*, 2023. Citado 6 vezes nas páginas 8, 12, 13, 30, 32 e 33.

KIMBALL, R.; ROSS, M. *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*. 3. ed. [S.l.]: John Wiley & Sons, 2013. Citado 3 vezes nas páginas 14, 19 e 33.

KLEPPMANN, M. *Designing Data-Intensive Applications: The Big Ideas Behind Reliable, Scalable, and Maintainable Systems*. [S.l.]: O'Reilly Media, 2017. Citado na página 14.

LIAO, S. W.; ZHANG, X. Y.; LIN, F. Y. Schema evolution in big data systems: A review. *IEEE Access*, v. 8, p. 17456–17467, 2020. Citado 2 vezes nas páginas 14 e 34.

POLISETTY, S. M.; PENDYALA, S. K.; PRABHAKARAN, S. P. Enhancing data quality in streaming data pipelines using delta live tables. *International Journal of Research in Computer Applications and Information Technology (IJRCAIT)*, v. 6, n. 1, p. 87–96, 2023. Citado 4 vezes nas páginas 12, 15, 33 e 34.

REIS, J.; HOUSLEY, M. *Fundamentals of Data Engineering: Plan and Build Robust Data Systems*. [S.l.]: O'Reilly Media, 2022. Citado 5 vezes nas páginas 12, 14, 16, 32 e 33.

APÊNDICE A – Glossário de termos técnicos

Este apêndice tem por objetivo apresentar as definições dos principais termos técnicos, conceitos e jargões da área de Engenharia de Dados utilizados ao longo do texto.

- **API (*Application Programming Interface*):** Conjunto de definições e protocolos que permite a comunicação e a integração entre diferentes sistemas ou aplicativos de *software*.
- **Arquitetura *Medallion*:** Padrão de projeto de organização de dados que divide os arquivos em camadas lógicas (comumente chamadas de *Bronze, Silver* e *Gold*), com o objetivo de melhorar progressivamente a estrutura e a qualidade das informações a cada etapa do processamento (GUJJALA, 2023).
- ***Bot*:** Aplicação de *software* concebida para executar ações e rotinas pré-programadas de forma automatizada, frequentemente operando através de comandos em aplicativos de comunicação.
- ***Business Intelligence* (BI):** Conjunto de teorias, metodologias e tecnologias (como o Power BI ou Tableau) que transformam dados brutos em informações significativas e úteis para a tomada de decisão estratégica do negócio.
- **Camada *Bronze* (L0):** Camada inicial de armazenamento na Arquitetura *Medallion* onde os dados brutos (*raw data*) são mantidos em seu estado original, exatamente como foram extraídos das fontes, sem aplicação de filtros ou transformações estruturais (GUJJALA, 2023).
- **Camada de Apresentação (*View*):** Camada lógica operando sobre a camada *Gold*, responsável por filtrar, deduplicar e expor os dados finais de maneira versátil para os analistas e ferramentas de visualização (REIS; HOUSLEY, 2022).
- **Camada *Gold* (L2):** Camada final onde os dados, já limpos e validados, são agregados e transformados com base em regras de negócio específicas, ficando prontos e otimizados para o consumo analítico e a geração de relatórios (GUJJALA, 2023).
- **Camada *Raw* (Crua):** Zona de pouso inicial (*landing zone*) de um *pipeline* de dados, responsável por receber e armazenar os arquivos externos exatamente em seu formato original, antes de qualquer processamento.

- **Camada *Silver* (L1):** Camada intermediária na qual os dados provenientes da camada *Bronze* passam por processos de limpeza, padronização, deduplicação e validação de qualidade contra contratos predefinidos (GUJJALA, 2023).

- **Contrato de Dados (*Data Contract*):** Acordo técnico e formal que define a estrutura, o formato, os padrões de qualidade e o comportamento esperado dos dados na transição entre sistemas ou camadas, garantindo a imposição de esquemas (*schema enforcement*) para a confiabilidade do sistema (ARMBRUST et al., 2020).

- ***Data Warehouse*:** Repositório centralizado e estruturado de dados projetado para suportar análises corporativas históricas e relatórios estratégicos (KIMBALL; ROSS, 2013).

- ***DataFrame*:** Estrutura de dados tabular bidimensional e heterogênea, amplamente utilizada na linguagem Python (como na biblioteca Pandas), onde os dados são alinhados em linhas e colunas.

- **ETL (*Extract, Transform, Load*):** Processo tradicional de integração de dados que envolve a extração de informações de diversas fontes, sua transformação para um formato adequado e, por fim, o carregamento em um repositório centralizado, prática otimizada pelas modernas arquiteturas de *pipelines* (GUJJALA, 2023).

- ***Fail-fast* (Falhar Rapidamente):** Princípio de engenharia de *software* no qual o sistema é projetado para interromper a sua execução imediatamente ao encontrar uma quebra de contrato estrutural, evitando a propagação de falhas em cascata para camadas analíticas.

- ***Fan-out*:** Fenômeno indesejado em operações de cruzamento ou transformação de bases de dados (como despivoteamentos e união de matrizes) no qual o número de instâncias resultantes multiplica-se de forma incorreta (REIS; HOUSLEY, 2022).

- **Granularidade:** Nível de detalhe, divisão ou resumo dos dados em uma estrutura. Ao longo de um *pipeline*, a granularidade pode transitar de estritamente unitária (um relatório por arquivo) para abrangente e consolidada (múltiplas fontes em um único repositório).

- **Ingestão de Dados:** Processo de coleta e importação de dados de diversas origens (como APIs, arquivos em lote ou bancos de dados) para um ambiente de armazenamento ou processamento primário (como a Camada *Bronze*) (POLISETTY; PENDYALA; PRABHAKARAN, 2023).

- ***Logs*:** Registros textuais e estruturados gerados em tempo real pela execução de um *software*, utilizados para auditar comportamentos, monitorar o desempenho e rastrear os motivos exatos de falhas técnicas.

- ***Melt* (Despivoteamento):** Operação de transformação lógica que converte variáveis dispostas horizontalmente em linhas, alterando a estrutura da matriz para um formato longo (*long format*), padrão ideal para motores de *Business Intelligence*.

- ***Outlier*:** Ponto ou instância de dado que difere expressivamente de outras observações em uma mesma amostra ou série histórica, podendo indicar tanto uma anomalia matemática de extração quanto uma mudança real de mercado na origem.

- ***Parser*:** Algoritmo ou rotina desenvolvida para analisar uma estrutura de dados de entrada (como um arquivo de texto, CSV ou PDF complexo) e extrair os parâmetros e informações relevantes de forma legível para o processamento subsequente.

- ***Pipeline* de Dados:** Conjunto automatizado de processos e fluxos que realiza a extração, o processamento, a validação e o carregamento de dados de um sistema de origem para um ambiente de destino, garantindo o fluxo contínuo e a qualidade das informações (POLISETTY; PENDYALA; PRABHAKARAN, 2023).

- **Qualidade de Dados (*Data Quality*):** Medida da condição dos dados baseada em fatores como precisão, completude, consistência e confiabilidade, assegurada através de processos de validação e limpeza implementados durante o fluxo de dados (POLISETTY; PENDYALA; PRABHAKARAN, 2023).

- **Reconciliação de Dados (Validação Horizontal e Vertical):** Técnicas de auditoria matemática utilizadas para garantir que a soma de partes de um registro corresponda de forma exata aos totais informados pela fonte original, mitigando erros de extração (POLISETTY; PENDYALA; PRABHAKARAN, 2023).

- ***Schema* (Esquema):** Estrutura lógica que atua como a ferramenta de validação de um contrato de dados, especificando os nomes das colunas, os tipos de dados exigidos e as restrições de obrigatoriedade, sendo essencial para lidar com a evolução estrutural em sistemas de *Big Data* (LIAO; ZHANG; LIN, 2020).

- ***Webhook*:** Mecanismo de comunicação entre sistemas que permite que uma aplicação (como um *bot* do Telegram) envie informações ou comandos em tempo real para outra (como o GitHub) assim que um evento específico ocorre.